


Análisis Espacial

Datos georreferenciados y procesos aleatorios

Mariano Córdoba, Pablo Paccioiretti y Ximena Porcasi

Instituto Gulich, octubre de 2026



Docentes



Ximena Porcasi

ximena.porcasi@ig.edu.ar



Mariano Córdoba

mariano.cordoba@unc.edu.ar




Pablo Paccioretti

pablopaccioretti@agro.unc.edu.ar

Cronograma

Clase	Fecha	Modalidad	Tema
1	Mié 7/10	Presencial	Introducción. Estadística espacial y datos geoposicionados. Procesos espaciales. Práctico: datos espaciales en R
2	Jue 8/10	Presencial	Datos geoestadísticos, patrones de puntos y lattice. Estructura espacial. Práctico: índices de autocorrelación espacial
3	Vie 9/10	Virtual	Ajuste de semivariogramas empíricos y teóricos
4	Mar 13/10	Presencial	Métodos de interpolación espacial
5	Mié 14/10	Presencial	Validación cruzada. Kriging regresión. Modelos de predicción con múltiples capas de datos
6	Jue 15/10	Virtual	Modelos lineales mixtos
7	Vie 16/10	Presencial	Análisis de datos puntuales. Datos de conteo y binarios
8	Lun 19/10	Presencial	Datos puntuales, de conteo y binarios. Datos lattice con GeoDa. Conceptos de riesgo
9	Mar 20/10	Virtual	Consultas
10	Jue 22/10	Presencial	Seminario de integración. Presentación de trabajos finales

Un mismo mapa, dos preguntas



Delitos registrados en la ciudad de Córdoba

¿Cuántos delitos ocurrieron a menos de 500 m de una escuela?

Análisis espacial


Una operación geométrica: buffer y conteo. El resultado es un número exacto; no hay modelo de probabilidad.

¿Están más agrupados de lo que esperaríamos si ocurrieran al azar?

Estadística espacial (patrones de puntos)

Compara lo observado con un modelo de referencia y la respuesta viene con incertidumbre. Lo veremos más adelante en el curso.

Otros datos, otras preguntas




Riesgo relativo por unidad espacial

¿Las unidades vecinas tienen un riesgo más parecido de lo esperable por azar?

Estadística espacial (datos de área)

Índice de Moran y matriz de vecindad.



Valor de la tierra rural, predicho a partir de puntos muestreados

¿Cuánto vale la tierra en un campo sin dato, y con qué error?

Geoestadística

Semivariograma y kriging.

La diferencia no está en el mapa sino en la pregunta, en el tipo de dato y en si la respuesta necesita un modelo de probabilidad.

Análisis espacial, estadística espacial y geoestadística

Análisis espacial

Toda operación que usa la ubicación: superposición, buffers, distancias, accesibilidad, interpolación determinística (IDW, Voronoi).

Estadística espacial

Modelo de probabilidad para los datos: incertidumbre e inferencia.

Aprendizaje automático
espacial (RF, RF-kriging)

Geoestadística

Dominio continuo.
Variograma, kriging.

Datos de área

Unidades fijas. Moran,
SAR, CAR.

Patrones de puntos

Ubicaciones aleatorias.
Intensidad,
agrupamiento.

Volviendo a las preguntas

- Delitos a menos de 500 m de una escuela: **análisis espacial**.
- Delitos agrupados o barrios vecinos parecidos: **estadística espacial**.
- Valor de la tierra donde no hay dato, con su error: **geoestadística**.

Los límites son difusos: el aprendizaje automático predice bien pero no siempre tiene un modelo probabilístico explícito.


Tipos de datos espaciales

Proceso aleatorio: conjunto de variables aleatorias $Z(x)$ observadas en la posición x , definida por un vector de coordenadas en un dominio D . Según la naturaleza de D , cambia qué es aleatorio:

1. Datos geoestadísticos

Las ubicaciones son fijas; lo aleatorio es el valor.


D es continuo. Interesa predecir en sitios no observados.



2. Datos de área (lattice)

Las unidades son fijas y discretas; lo aleatorio es el valor de cada unidad.


Interesa suavizar, mapear y estudiar la relación entre vecinos.




3. Patrones de puntos

Lo aleatorio es la ubicación de los eventos.


D es aleatorio. Interesa detectar agrupamiento o regularidad.




Tipos de datos espaciales: ejemplos




Geoestadístico - valor de la tierra rural (predicción)




Geoestadístico - variabilidad del rendimiento en un lote




Área - MO media por departamento



Área - riesgo relativo por unidad espacial



Puntos - delitos registrados en la ciudad de Córdoba



Puntos - patrones agregado, regular y aleatorio

¿Cómo se analizan los datos espaciales?

Técnicas clásicas

- Autocorrelación espacial: dependencia entre ubicaciones (índice de Moran)
- Interpolación espacial: estimación en sitios no observados (kriging, IDW)
- Regresión espacial: relaciones entre variables espaciales (SAR, CAR)

Aprendizaje automático

- CART, Random Forest, XGBoost, GBM: clasificación y predicción
- Redes neuronales (CNN, DNN): patrones espaciales complejos

Análisis multivariado

- PCA, PCA espacial: reducen dimensionalidad
- Clustering: agrupan sitios o áreas similares
- PLS: Predicción de respuesta uni y multivariada

Modelos mixtos y jerárquicos

- Lineales mixtos y jerárquicos bayesianos: incorporan dependencia espacial y efectos aleatorios

Software

- QGIS, ArcGIS: visualización y análisis geoespacial
- R (sf, gstat, randomForest, INLA) y Python (geopandas, scipy, pykrige, TensorFlow)


La primera ley de la geografía

“Todas las cosas están relacionadas entre sí, pero las cosas más próximas en el espacio tienen una relación mayor que las distantes.”

Tobler (1970)

- En los modelos de estadística espacial, los datos cercanos tienden a parecerse más que los datos distantes.
- Esa dependencia es información (permite predecir donde no medimos) y también un problema (los datos vecinos repiten información).

Mapa de variabilidad espacial



Rendimiento en un lote: los valores altos y bajos aparecen en sitios contiguos.

Estadística clásica y geoestadística

Estadística clásica

- Los datos son realizaciones independientes de una misma variable aleatoria (misma distribución).
- Se busca estimar los parámetros de esa distribución.
- Se plantean supuestos referidos a la parte del error aleatorio del modelo.


Geoestadística

- Cuando los datos están ubicados en el espacio geográfico, el supuesto de independencia no se cumple.
- Observaciones próximas tienen valores “parecidos”; las más alejadas, una correlación menor.

Para discutir: si tengo 200 datos autocorrelacionados, ¿cuánta información independiente tengo?



Proceso aleatorio

- Las características del ambiente, como el suelo, son el producto de muchos procesos físicos, químicos y biológicos que interactúan entre sí.
- Esos procesos están físicamente determinados, pero sus interacciones son tan complejas que la variación parece aleatoria.
- Una solución determinística para cuantificar esa variación está hoy fuera de alcance.
- La propuesta de Matheron (1965): **tratar la variación como si fuera aleatoria.**
- La aleatoriedad es un modelo mental del mundo, no una propiedad del ambiente (Oliver y Webster, 2015).



Una superficie de apariencia errática, pero con estructura espacial.


Un proceso, muchas realizaciones posibles



- Cuatro mapas simulados con la misma media, varianza y rango: cambia dónde están los valores altos y bajos, no la estructura.
- En el sitio x_0 (punto blanco), Z toma un valor distinto en cada realización. Con 500 realizaciones obtenemos la distribución de $Z(x_0)$.
- **Nosotros observamos un solo mapa.** Para estimar media y covarianza promediamos en el espacio, no entre realizaciones.

Proceso aleatorio: definición

- El valor de una propiedad z en un lugar x , $z(x)$, es uno de los infinitos valores posibles de una variable aleatoria $Z(x)$ en ese lugar: una realización del proceso.
- El conjunto de variables aleatorias en todos los lugares de una región (también infinitos) es un proceso aleatorio, que también se denota $Z(x)$.
- **En la figura:** cada curva es la distribución de Z en ese sitio; el punto naranja es el valor que tomó en esta realización (el mapa de fondo).
- Los sitios cercanos caen en zonas parecidas de su curva: **eso es la autocorrelación espacial.**



Caracterización de una función aleatoria

Esperanza en x: $\mu(x) = E[Z(x)]$

Varianza en x: $\sigma^2(x) = \text{var}[Z(x)]$

Covarianza entre x_1 y x_2 : $C(x_1, x_2) = \text{Cov}[Z(x_1), Z(x_2)]$
 $= E[\{Z(x_1) - \mu(x_1)\}\{Z(x_2) - \mu(x_2)\}]$

Recordatorio (muestral)

$$\widehat{cov}(X, Y) = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{n - 1}$$

$$r = \frac{\widehat{cov}(X, Y)}{(s_X s_Y)}$$

Sitio	x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8	x_9	x_{10}
Valor	4	2	3	3	5	1	3	4	3	1

- ¿Cuánto vale la esperanza en x_1 ? ¿Y la covarianza entre x_1 y x_2 ?
- Sólo hay una realización de Z en cada punto: con estos datos no podemos calcular esos momentos.
- Hace falta un supuesto adicional: **que el proceso sea estacionario.**



Estacionariedad de segundo orden

La estacionariedad permite asumir el mismo grado de variación de un lugar a otro. El proceso se representa como

$$Z(x) = \mu + \varepsilon(x)$$

donde μ es la media del proceso y $\varepsilon(x)$ una cantidad aleatoria de media cero con covarianza

$$C(h) = E[\varepsilon(x) \varepsilon(x + h)] = E[\{Z(x) - \mu\}\{Z(x + h) - \mu\}] = E[Z(x) Z(x + h)] - \mu^2$$

Supuestos de estacionariedad de segundo orden

- i) La media es constante: $E[Z(x)] = \mu$ para todo x .
- ii) La covarianza depende sólo de h , la separación entre sitios en distancia y dirección. En particular, la varianza $C(0) = \sigma^2$ es finita y constante.


Estacionariedad intrínseca y semivariograma

- Si la varianza no es finita (la variación sigue creciendo con la distancia), $C(h)$ no existe.
- Matheron propuso una hipótesis más débil: que sean estacionarios los incrementos $Z(x) - Z(x + h)$.

$$E[Z(x) - Z(x + h)] = 0$$

$$\gamma(h) = \frac{1}{2} \text{var}[Z(x) - Z(x + h)] = \frac{1}{2} E[\{Z(x) - Z(x + h)\}^2]$$

- Si el proceso es estacionario de segundo orden, ambos existen y son equivalentes: $\gamma(h) = C(0) - C(h)$.
- **Ojo:** la hipótesis intrínseca también supone media constante. Una media que cambia en el espacio se modela con una tendencia $\mu(x)$.







Nombres

$C(h)$: función de covarianza o covariograma



$\rho(h) = C(h) / C(0)$: correlograma

$\gamma(h)$: semivariograma; su valor a una distancia h es la semivarianza

¿Estacionario o con tendencia?



A - CE30 con tendencia en y



B - CE30 sin tendencia clara en x ni en y

La aleatoriedad y la estacionariedad son atributos que asumimos en nuestros modelos de variación; no son propiedades del mundo real ni de los datos, y no hay una prueba formal para ellas.

Tendencia


- Un proceso que parece estacionario a una escala puede mostrar tendencia, es decir, un componente sistemático, a otra escala.
- $\mu(x)$ es un término de tendencia determinista que reemplaza a la media constante μ .
- El variograma se calcula a partir de los residuos $\varepsilon(x)$.

$$Z(x) = \mu(x) + \varepsilon(x)$$


$$\gamma(h) = \frac{1}{2} E[\{\varepsilon(x) - \varepsilon(x + h)\}^2]$$

Los residuos de una tendencia estimada por mínimos cuadrados tienden a subestimar el variograma, sobre todo a distancias grandes. Lo retomamos con kriging universal y kriging regresión.

Media constante o tendencia



$$Z(x) = \mu + \varepsilon(x)$$



$$Z(x) = \mu(x) + \varepsilon(x)$$

$$\mu(x) = \sum_k \beta_k q_k(x), \quad k = 0, \dots, p$$

Mapa del curso

$$Z(x) = \mu(x) + \varepsilon(x)$$

Buena parte del curso consiste en decidir cómo modelar la tendencia $\mu(x)$ y qué hacer con la parte aleatoria $\varepsilon(x)$.

Tema	Tendencia $\mu(x)$	Parte aleatoria $\varepsilon(x)$
Exploración y autocorrelación	Detectarla: gráficos contra coordenadas	¿Hay dependencia? Índice de Moran
Semivariogramas	Constante, o tendencia removida	Describir la dependencia con $\gamma(h)$
Interpolación (kriging)	Constante desconocida (kriging ordinario)	Predecir usando $\gamma(h)$
Kriging regresión y modelos con capas	Función de coordenadas o covariables (regresión, RF)	Kriging de los residuos
Modelos lineales mixtos	$X\beta$: tratamientos y covariables	Estructura espacial en R, estimada por REML
Patrones de puntos y datos de área	Intensidad o riesgo por unidad	Dependencia entre vecinos (matriz W)

Para leer

Oliver, M. A. y Webster, R. (2015). *Basic Steps in Geostatistics: The Variogram and Kriging*. SpringerBriefs in Agriculture. Springer.

Capítulos 1 y 2: variables regionalizadas, procesos aleatorios, estacionariedad y tendencia. Está en la carpeta Bibliografía del curso.

Práctico: 01_procesos_aleatorios.R (simulación de realizaciones de un proceso aleatorio).