




Aplicación de imágenes de radar de apertura sintética

Teledetección en microondas: fundamentos físicos y extracción de información


Clase 7.1: Árboles de decisión - Evaluación de exactitud

Dra. Mercedes Salvia - msalvia@iafe.uba.ar

Clasificadores de decisión

Un **árbol de decisión** es una estructura similar a un diagrama de flujos, que permite **clasificar** la información de **entrada** en función de **variables** relacionadas con los mismos datos de entrada y un conjunto de **reglas**. Estas reglas hacen referencia a **operaciones** cuya respuesta tiene que ser **binaria**.


Clasificación en árbol



Si es el usuario quién define las reglas de decisión, este es un método de **clasificación supervisada**. Un ejemplo de **variables** podrían ser el **coeficiente de retrodispersión en HH**, el **cociente VV/VH** , y las reglas pueden incluir valores puntuales o resultantes de operaciones sobre las mismas variables, por ejemplo si es o no **mayor que la media de una polarización**, **si pertenece o no a un percentil de la distribución**, etc.

Clasificadores: árboles de decisión

- Objetivo:
 - Predicción óptima de clases a partir de un conjunto de valores de variables (σ^0 , reflectancia, temperaturas, otros).
- Enfoque básico:
 - Aprendizaje supervisado utilizando datos de entrenamiento
- Atributos principales:
 - No paramétrico
 - Capaz de manejar datos ruidosos
 - Capaz de identificar patrones no lineales.



Tipos de árboles de decisión.


Con respecto a las variables establecidas en los nodos:

- **Univariado**: en cada nodo la decisión depende de una sola variable, (aunque en el árbol completo pueden incluirse más variables)
- **Multivariado**: en cada nodo (o al menos en algunos de ellos) la decisión depende de los valores de más de una variable.


Con respecto al diseño del árbol:

- **Balanceados**: todas las ramas terminales se encuentran en el mismo nivel. Es el más optimizado computacionalmente
- **Degenerados**: de cada nodo se desprende un nuevo nodo y una rama terminal. Son mucho más lentos que los anteriores, ya que en general, en cada nodo solo se asignan unos pocos píxeles
- **Intermedios**: se encuentran en una situación intermedia entre balanceados y degenerados.


Degenerado



Balanceado



Intermedio



EJEMPLO

Ejemplo de árbol “univariado” y “degenerado”.

Clasificación de un conjunto de observaciones caracterizadas por dos variables NDVI y Temperaturas.

Los datos se particionan sucesivamente sobre la base de la comparación con una única variable en cada nodo.

Se asigna una clase a la observación según corresponda.






Figure 3. Example of a two-class data set that may be classified by using either a linear combination test (left) or a univariate decision tree (right).

EJEMPLO

The Potential of Multifrequency Polarimetric SAR in Assessing Agricultural and Arboreal Biomass



Upper: classification map obtained by using, for each pixel, the algorithm described in the text. Lower: ground-truth map. Mixed vegetation includes wheat, alfalfa and pastures. First AIRSAR flight (22/06/91).

EJEMPLO

Spatial prediction of landslide susceptibility using a decision tree approach: a case study of the Pyeongchang area, Korea





Figure 6. Architecture of the decision tree model. A decision tree consists of the following three elements: node, condition, and production (*p*-value). Moreover, there are three types of node – the root (A), internal (B, C, and D), and terminal nodes (R).



EJEMPLO

An Approach to Use Polarimetric Signature for Land Cover Classification



Fig. 5. Proposed decision tree classification Algorithm





TABLE III. OVERALL ACCURACY AND KAPPA COFFICIENT

Classification Techniques	Overall Accuracy	Kappa Coefficient
Decision Tree Classification	78.81%	0.73
Maximum Likelihoods	75.89%	0.69
K-Means	56.7%	0.45
ISO-Data	56.77%	0.46


EJEMPLO

Monitoring Rice Phenology Based on Backscattering Characteristics of Multi-Temporal RADARSAT-2 Datasets




EJEMPLO


Monitoring Rice Phenology Based on Backscattering Characteristics of Multi-Temporal RADARSAT-2 Datasets (cont.)




(a)



(b)





(c)



(d)

RANDOM FOREST

- ❖ Clasificador basado en árboles de decisión
- ❖ Clasificador Supervisado y No Paramétrico
- ❖ El modelo de Random Forest separa la muestra de entrenamiento:
 - 2/3 para generar los múltiples árboles de decisión,
 - 1/3 para estimar errores e importancia de las variables
- ❖ Las clases son asignadas a los píxeles basadas en el principio de mayoría, es decir cada árbol de decisión vota para decidir qué clase asignar a cada píxel



RANDOM FOREST

Ventajas

- En general no tiene problemas de overfitting (sobreajuste)
- No es sensible a outliers en el set de entrenamiento
- Fácil de parametrizar

Limitaciones

- Limitado por la muestra de entrenamiento (no puede predecir si nunca lo vio)
- Los datos de entrenamiento deben capturar todo el rango de valores (espectrales, de polarización, etc.).

EJEMPLOS

RANDOM FORESTS FOR BUILDING DETECTION IN POLARIMETRIC SAR DATA

Ronny Hänsch and Olaf Hellwich

Technische Universität Berlin
Computer Vision and Remote Sensing
FR3-1
Franklinstr. 28/29
10587 Berlin, Germany

978-1-4244-9566-5/10/\$26.00 ©2010 IEEE IGARSS 2010



(a) TerraSAR-X image



(b) Classification result

AN EFFICIENT USE OF RANDOM FOREST TECHNIQUE FOR SAR DATA CLASSIFICATION

Shruti Gupta¹, Dharmendra Singh², K P Singh³, Sandeep Kumar⁴

^{1,4}Department of Computer Science and Engineering

²Department of Electronics and Communication Engineering

^{1,2,4}Indian Institute of Technology Roorkee, Roorkee (UK), India

³Department of Electronics Engineering, Indian Institute of Technology (BHU) Varanasi, Varanasi, India

978-1-4799-7929-5/15/\$31.00 ©2015 IEEE

IGARSS 2015




Fig 1. Flowchart of the Proposed Methodology

EJEMPLOS




Fig 2. (a) Texture based classified image (b) SAR observables statistics based classified image (c) PDF based classified image (d) Color based classified image (e) Random forest classified image

TABLE I. CLASSIFICATION ACCURACY

Classification Approach	Producer Accuracy				Overall Accuracy
	Water	Bare Soil	Urban	Vegetation	
Texture Based	25%	82%	84%	54%	64%
SAR Observables Based	75%	48%	71%	89%	70%
PDF Based	77%	57%	92%	88%	77%
Color Based	98%	74%	98%	63%	83%
Random Forest	89%	70%	99%	98%	88%



Random Forest and Rotation Forest for fully polarized SAR image classification using polarimetric and spatial features



Peijun Du^{a,b,*}, Alim Samat^{a,b}, Björn Waske^c, Sicong Liu^d, Zhenhong Li^e

^aKey Laboratory for Satellite Mapping Technology and Applications of State Administration of Surveying, Mapping and Geoinformation, Nanjing University, China

^bJiangsu Center for Collaborative Innovation in Geographical Information Resource Development and Application, China

^cDepartment of Earth Sciences, Freie Universität Berlin, Germany

^dDepartment of Information Engineering and Computer Science, University of Trento, Italy

^eSchool of Civil Engineering and Geosciences, Newcastle University, United Kingdom

<http://dx.doi.org/10.1016/j.isprsjprs.2015.03.002>




Fig. 1. Technical flow.

EJEMPLOS





Fig. 6. Classification maps of Random Forest (Row 1), Rotation Forest (Row 2), Support Vector Machine (Row 3) and Wishart classification results on data set 1 using different features (F1 represents [T3-db]; F2 represents [T3-db, span, MPs]; F3 represents [T3-db, span, TFs]; F4 represents [T3-db, span, TFs, MPs]).



Aplicación de imágenes de radar de apertura sintética

Teledetección en microondas: fundamentos físicos y extracción de información

Clase 7.1.2: Evaluación de exactitud

Dra. Mercedes Salvia - msalvia@iafe.uba.ar

INFERENCIA ESTADÍSTICA

El proceso mediante el cual se evalúa la precisión o exactitud de la clasificación de una imagen implica:

- ❖ La comparación del mapa resultante de la clasificación con datos de referencia que se supone son ciertos (en general los mismos usados para obtener las etiquetas del mapa)
- ❖ Obtener información sobre una población a partir de muestras (del mapa a evaluar y de la información de referencia, ya sea este un mapa o no)

A partir de eso:

- ❖ Se identifica errores en las clasificaciones diseñando e implementando una evaluación de exactitud

DISEÑO MUESTRAL

Objetivo: obtener información que sea representativa de la población (es decir, el número de clases y el tamaño de las clases)

Reglas Básicas:

- ✓ Los datos que se usan para evaluar la precisión deben ser independientes de los datos de entrenamiento (para una clasificación supervisada)
- ✓ Evitar sesgos es clave
- ✓ Se debe muestrear todas las clases

Como no se puede identificar cada pixel, se necesita una muestra como punto de referencia para determinar la posición de los puntos:

- ✓ Tamaño de la muestra
- ✓ Método muestral

CLASIFICACIÓN BINARIA

Problema general: separar los elementos de un conjunto en dos grupos bajo cierta/s regla/s de clasificación (en general solo uno de los grupos es el de nuestro interés)

Algunos ejemplos:


- Examen médico: enfermo – no enfermo, test de embarazo
- Educación: aprobado – no aprobado
- Bromatología: apto – no apto para el consumo
- Control de calidad en fábricas: seguro – no seguro

Queremos evaluar la clasificación. ¿Qué puede pasar?

Ejemplo: Test de Embarazo

- Verdadero Positivo (Acierto): Test positivo, paciente embarazada.
- Falso positivo: Test positivo, paciente no embarazada.
- Falso Negativo: Test negativo, paciente embarazada.
- Verdadero negativo: Test negativo, paciente no embarazada.

Type I error
(false positive)



Type II error
(false negative)



MATRIZ DE CONFUSIÓN (1 SOLO TEST)

		Clase Verdadera	
		Positivo	Negativo
Clase Predicha (resultado del test)	Positivo	VP: P_A	FP: P_{FP}
	Negativo	FN=1- P_A	VN=1- P_{FP}


Probabilidad de VP (acierto): P_A

Probabilidad de Falso Positivo: P_{FP}

Probabilidad de Falso Negativo= 1- P_A

Probabilidad de Verdadero Negativo=1- P_{FP}

¿SI HACEMOS VARIOS TESTS?



Precisión: proporción de píxeles seleccionados que verdaderamente pertenecían a esa clase (de las personas a las que les dije que estaban embarazadas cuantas efectivamente lo estaban)

Exhaustividad (recall): proporción de píxeles que identifiqué en una clase de los que debería haber identificado (de todas las personas embarazadas que testee, a cuantas les dije que lo estaban)

How many retrieved items are relevant?

$$\text{Precision} = \frac{\text{true positives}}{\text{true positives} + \text{false positives}}$$

How many relevant items are retrieved?

$$\text{Recall} = \frac{\text{true positives}}{\text{true positives} + \text{false negatives}}$$


$$\text{Precisión} = \frac{\text{Aciertos}}{\text{Aciertos} + \text{Falsos positivos}}$$

$$\text{Exhaustividad} = \frac{\text{Aciertos}}{\text{Aciertos} + \text{Falsos negativos}}$$

F-SCORE (VALOR F)


Problema: ninguna de las 2 por si sola alcanza para evaluar el desempeño del test, ya que precisión y exhaustividad compiten entre sí.
Es necesario encontrar un compromiso entre ambas métricas

$$F = 2 \frac{\text{Precisión} * \text{Exhaustividad}}{\text{Precisión} + \text{Exhaustividad}}$$



Preciso

Precisión: 90%
Exhaustividad: 38%
F-Score: 0,53




Exhaustivo

Precisión: 33%
Exhaustividad: 90%
F-Score: 0,49

PRECISIÓN VS EXHAUSTIVIDAD

Sitio 1 - 2011. 661 píxeles deforestados, 31100 sin enmascarar



Compromiso

Precisión: 73%

Exhaustividad: 77%

F-Score: 0,75

CONCLUSIONES

Todos los Test/clasificadores tienen una probabilidad de acertar y una probabilidad de falso positivo.

- Correr estos tests sobre grandes conjuntos nos lleva a definir precisión y exhaustividad.
- Estas métricas compiten entre sí. Para mantener un equilibrio entre ellas introducimos el F-Score.
- Sin embargo, el F-Score por sí solo no alcanza para evaluar el desempeño.

El usuario debe decidir si favorece la precisión o la exhaustividad

CLASIFICACIÓN MÚLTIPLE (NO BINARIA)

La exactitud de una clasificación de múltiples clases realizada se evalúa a través de diferentes parámetros derivados de la matriz de confusión cuyo significado se expresa de la siguiente manera:

- **Exactitud general de la clasificación**: Se calcula como el número de píxeles bien clasificados sobre el número total de píxeles en las muestras de evaluación.
- **Exactitud del usuario**: Es un indicador del **error por comisión**, o sea es un indicador del porcentaje de píxeles que no perteneciendo a esa clase fueron clasificados como si lo fueran.
- **Exactitud del productor**: Es un indicador del **error por omisión**, o sea es un indicador del porcentaje de píxeles que perteneciendo a esa clase fueron clasificados como otra.
- **Índice Kappa** (Hudson y Ramm, 1987; Congalton, 1988): Es un estimador de la exactitud total de la clasificación pero toma en cuenta el efecto del azar, a través del producto de los totales marginales.

Evaluación de la clasificación (2)

Evaluación de la exactitud

A través de este procedimiento se evalúa la calidad del mapa elaborado. La exactitud obtenida para todo el mapa y para cada clase en particular se calcula construyendo la matriz de confusión de la clasificación.

MATRIZ DE ERROR

Datos de referencia

Datos clasificados

	J	F	Total
J	24	6	30
F	16	42	58
Total	40	48	88

La sumatoria de los valores de dicha diagonal dividido el total de datos evaluados corresponde al valor total de exactitud del mapa.

$$\text{Exactitud total del mapa} = (24 + 42) / 88 = 0.75 = 75\%$$

La exactitud del productor indica la probabilidad de que una muestra de referencia esté correctamente clasificada.

La exactitud del usuario indica la confiabilidad del mapa para el usuario.

Exactitud del productor

$$J = 24 / 40 = 60 \%$$

$$F = 42 / 48 = 87 \%$$

Exactitud del usuario

$$J = 24 / 30 = 80 \%$$

$$F = 42 / 58 = 72 \%$$

Evaluación de la clasificación (3)

Indice Kappa

$$K = \frac{P(a) - P(e)}{1 - P(e)}$$

	J	F	Total
J	24	6	30
F	16	42	58
Total	40	48	88

Exactitud total = $(24 + 42) / 88 = 0.75$

Valor de K	Interpretación
< 0	Sin concordancia
0 – 0,2	Concordancia leve
0,2 – 0,4	Concordancia regular
0,4 – 0,6	Concordancia moderada
0,6 – 0,8	Concordancia sustancial
0,8 - 1	Concordancia casi perfecta

$$K = \frac{N \sum_{i=1}^r X_{ii} - \sum_{i=1}^r X_{i+} * X_{+i}}{N^2 - \sum_{i=1}^r X_{i+} * X_{+i}}$$

$$K = \frac{[88 * (24 + 42)] - [(30 * 40) + (58 * 48)]}{88^2 - [(30 * 40) + (58 * 48)]}$$

$$K = \frac{5808 - 3984}{7744 - 3984} = \frac{1824}{3760} = 0,48$$

CLASIFICACIÓN DE AMBIENTES Y ALCANCE DE INUNDACIÓN EN EL BAJO DELTA DEL RÍO PARANÁ MEDIANTE IMÁGENES MULTITEMPORALES RADARSAT/SAR

M. G. Parmuchi¹, H. Karszenbaum¹, P. Kandus², J. Tiffenberg¹

(1) CONICET - Instituto de Astronomía y Física del espacio (IAFE), Pabellón IAFE, Ciudad Universitaria (1428), Buenos Aires, Argentina. E-mail: gabriela@iafe.uba.ar, haydeek@iafe.uba.ar

(2) Laboratorio de Ecología Regional, Departamento de Biología - Facultad de Ciencias Exactas y Naturales Universidad de Buenos Aires (UBA) Ciudad Universitaria, Pab. II 4to.piso. (1428) Buenos Aires, Argentina. E-mail: pato@bg.fcen.uba.ar


Objetivos

- Analizar el contenido de información que la señal de radar aporta acerca de las propiedades de los ecosistemas.
- Implementar procedimientos de extracción de información de imágenes de radar en ambientes de humedal, a fin de obtener mapas de cobertura de vegetación y de alcance de inundación en ecosistemas de humedal y evaluar la calidad de los mismos.

Datos disponibles

Tipo de imagen	Fecha	Característica (banda, polarización, ángulo de incidencia)	Estación del año	Condición de inundación
SAR/Radarsat	Febrero 16/1997	C, (HH), S6 (41-46°)	Verano	Normal
	Marzo 16/1997	C, (HH), S1 (20-27°)	Verano	Normal
	Agosto 7/1997	C, (HH), S1 (20-27°)	Invierno	Normal
	Mayo 18/1998	C, (HH), S6 (41-46°)	Invierno	Inundado
	Mayo 22/1998	C, (HH), S1 (20-27°)	Invierno	Inundado
TM	Marzo 7/1997	Bandas 1-7	Verano	Normal

Nivel del agua del Río Paraná en el área de estudio



ÁREA DE ESTUDIO

Comprende el sector noroeste de las islas del Bajo Delta del Río Paraná, correspondiente a la Unidad de paisaje A o Planicie Deltaica. Esta zona presenta grandes islas que poseen una alta influencia de las crecientes del Río Paraná.

La región del Bajo Delta es un ecosistema de humedal sometido a mareas de agua dulce y desemboca en otro gran río con características estuáricas.







Imagen multitemporal del Bajo Delta del Río Paraná
(rojo: S1-Agosto 1997, verde: S1-Febrero 1997, azul: S6-Enero 1997)

Características morfológicas y grado de inundabilidad de los distintos tipos de vegetación

Primer Nivel	Vegetación herbácea		Vegetación leñosa
Formas de vida dominante	Herbáceas equisetoides	Herbáceas graminiformes	Árboles

Segundo Nivel		Juncales	Pajonales	Plantaciones de sauce	Plantaciones de álamo
Características estructurales	Altura	 ~ 2.5 m	 ~ 1.5 – 2.0 m	 ~ 12 m	 ~ 12 m
	Cobertura	< 80 %	100 %	< 100 %	< 100%
	Tronco	—	—	Erecto	Erecto
	Ramas	—	—	Abiertas y tías	Abiertas
	Hojas	Reducidas al tallo	Graminiformes hasta 1.5m long.	Lineal-lanceoladas	Aovadas
Grado de inundabilidad		Permanentemente inundados	Irregularmente expuestos	Regularmente Expuestos	

Interpretación de los distintos ambientes presentes en el área de estudio












Imagen multitemporal de radar (rojo: S1-agosto1997, verde: S6-Mayo1998, azul: S1-Mayo1998)



Mecanismo de interacción dominante de la señal de radar con los distintos ambientes


CONDICIÓN NORMAL

Juncal




Dispersión de doble rebote

Pajonal




Dispersión en volumen

Forestación




Dispersión en volumen




Reflexión especular


CONDICIÓN DE INUNDACIÓN




Reflexión especular



Dispersión en volumen




Dispersión en volumen




Dispersión de doble rebote

RESULTADOS 1: Diagrama de boxplots del coeficiente de retrodispersión de los distintos ambientes


S6-Febrero1997




S1-Marzo1997




S1-Agosto1997




S6-Mayo1998






S1-Mayo1998






Clasificación digital

RESULTADOS 2: Diagrama de Árbol de decisión elaborado para la obtención de mapas de ambientes y de alcance de inundación



Mapa de cobertura y condiciones de inundación durante el evento de “El Niño” de 1998 obtenido a partir de un clasificador de decisión.



RESULTADOS 5: Evaluación de la exactitud de los mapas de cobertura

CLASIFICADOR ISODATA		Datos de referencia				Total de pixeles por fila	Exactitud para el usuario	Error por comisión
		A	JI	MH	FS			
Datos clasificados	A	1569	0	0	0	1569	100	0
	JI	0	1484	425	363	2272	65.3	34.7
	MH	0	47	605	127	779	77.6	22.3
	FS	0	29	321	1894	2244	84.4	15.6
Total de pixeles por columna		1569	1560	1351	2384	6864		
Exactitud del productor		100	95.1	44.8	79.4		Exactitud total	
Error por omisión		0	4.9	55.2	20.6		80.8 %	

K= 0.74

CLASIFICADOR BASADO EN EL CONOCIMIENTO		Datos de referencia				Total de pixeles por fila	Exactitud para el usuario	Error por comisión
		A	JI	MH	FS			
Datos clasificados	A	1569	7	0	0	1576	99.6	0.4
	JI	0	1471	265	149	1885	78.0	22.0
	MH	0	41	572	49	662	86.4	13.6
	FS	0	30	500	2176	2706	80.4	19.6
	Total de pixeles por columna	1569	1549	1337	2374	6829		
Exactitud del productor		100	94.9	42.8	91.7		Exactitud total	
Error por omisión		0	5.1	57.2	8.3		84.8 %	

K= 0.79

La determinación de exactitud cuantitativa se realizo utilizando el mapa de vegetación existente y los informes de los productores forestales.